PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

Facultad de Ingeniería

Escuela de Ingeniería Informática

INFORME TRABAJO FINAL

INF3541-2 TALLER DE BASE DE DATOS

Integrantes: *Agustín Guzmán y Nicolás Leiva*

Fecha: *noviembre de 2026*

---

1. Introducción

Este informe documenta el diseño, la carga y la explotación de una base de datos PostgreSQL construida a partir de un catálogo de películas. Se describen el modelo, la carga mediante tablas de traspaso, los triggers de auditoría, los procedimientos almacenados, las consultas comparadas y el control de acceso.

2. Descripción del dataset

2.1. Fuente y autorización

El dataset es un catálogo de películas compuesto por diez archivos CSV, publicado originalmente en 2024. No cumple estrictamente el requisito de recencia del enunciado, pero su uso fue autorizado por el profesor.

Fuente: https://www.kaggle.com/datasets/gsimonx37/letterboxd.

2.2. Archivos y volumen

El conjunto ocupa aproximadamente 801 MB y contiene 941.597 películas. La Tabla 1 resume los archivos utilizados.

Archivo	Filas	Contenido
`movies.csv`	941.597	Películas
`posters.csv`	941.597	Enlaces de póster
`actors.csv`	5.798.450	Reparto
`crew.csv`	4.720.183	Equipo técnico
`studios.csv`	679.283	Estudios
`releases.csv`	1.332.782	Estrenos por país y fecha
`languages.csv`	1.038.762	Idiomas
`countries.csv`	693.476	Países por película
`genres.csv`	1.046.849	Géneros por película
`themes.csv`	125.641	Temas por película

Cuadro 1: Archivos del dataset y cantidad de filas.

Antes de cargar se revisaron los datos: hay 946 duplicados en actores, 1.282 en crew y 212 en estudios, que se eliminan con `DISTINCT`; 180.712 pósters y 802.193 taglines vacíos, que se guardan como `NULL`; y 33 roles con espacios Unicode, que se conservan tal como vienen.

3. Modelo de datos

3.1. Diagrama entidad-relación

El modelo tiene 19 tablas y está en tercera forma normal. La Figura 1 muestra el diagrama.

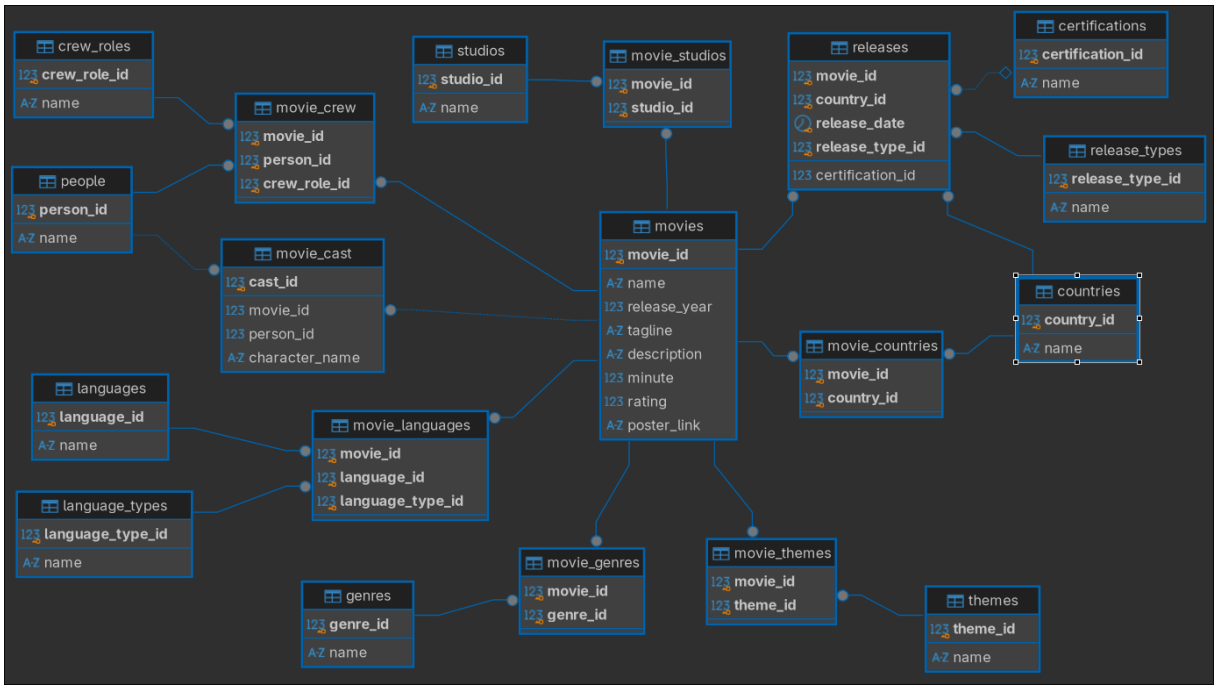


Figura 1: Diagrama entidad-relación del modelo.

3.2. Tablas y relaciones

El modelo se compone de `movies`, `people`, nueve catálogos (`countries`, `genres`, `themes`, `studios`, `language_types`, `languages`, `crew_roles`, `release_types` y `certifications`) y ocho relaciones (`movie_countries`, `movie_genres`, `movie_themes`, `movie_studios`, `movie_languages`, `movie_cast`, `movie_crew` y `releases`).

El póster se guarda en `movies.poster_link` porque cada película tiene como máximo uno. `people` unifica actores y crew: 2.479.949 nombres distintos.

4. Integridad y reglas de negocio

El esquema usa claves primarias, claves foráneas, restricciones de unicidad y restricciones `CHECK`. Las principales validan nombre no vacío, año entre 1870 y 2100, duración positiva, rating entre 0 y 5, fechas entre 1870 y 2100 y póster nulo o no vacío.

Las claves foráneas de las relaciones usan `ON DELETE CASCADE` hacia `movies`. Las claves hacia catálogos y personas impiden borrar un registro que esté en uso. Las reglas que involucran varias tablas se controlan en los procedimientos almacenados.

5. Carga de datos

Los CSV se copian con `\copy` a tablas `UNLOGGED` del schema `staging`, sin claves foráneas ni restricciones. Luego los scripts de `load` traspasan los datos con `INSERT ... SELECT`, aplicando `CAST`, `NULLIF`, `DISTINCT` y `JOIN` para resolver los catálogos por nombre.

El orden respeta las dependencias: películas, catálogos, personas, reparto y crew, y finalmente estrenos. Al terminar, `99_validate.sql` verificó los conteos principales: 941.597 películas, 2.479.949 personas, 5.797.504 de reparto, 4.718.901 de crew, 1.332.782 estrenos y 693.476 países por película.

6. Triggers de auditoría

La tabla `audit_log` registra la tabla afectada, la operación (`I`, `U` o `D`), la clave de la fila, los datos anteriores y nuevos en `JSONB`, el usuario y la fecha. Una función genérica es reutilizada por cuatro triggers `AFTER INSERT OR UPDATE OR DELETE` sobre `movies`, `people`, `studios` y `releases`.

Los triggers se crean después de la carga para no registrar las inserciones masivas. Una prueba de alta, modificación y baja deja este log:

```
 operation | row_key
-----------+-------------------------
 I         | {"movie_id": 999999999}
 U         | {"movie_id": 999999999}
 D         | {"movie_id": 999999999}
```

7. Procedimientos almacenados

Se implementaron cinco procedimientos para los mantenedores:

Procedimiento	Regla / comportamiento
`sp_movie_upsert`	Alta o modificación de una película. Exige nombre no vacío, año entre 1870 y 2100, duración positiva y rating entre 0 y 5.
`sp_movie_delete`	Baja de una película; las relaciones se eliminan por `ON DELETE CASCADE`.
`sp_studio_delete`	No permite eliminar un estudio con películas asociadas.
`sp_person_merge`	Fusiona dos personas: mueve reparto y crew y elimina el duplicado.
`sp_register_release`	Registra un estreno. La fecha no puede ser anterior al año de la película y crea los catálogos que falten.

Cuadro 2: Procedimientos almacenados y sus reglas de negocio.

Todos validan sus datos y terminan con `COMMIT`. Si se incumple una regla de negocio hacen `ROLLBACK` y lanzan una excepción; por ejemplo, `sp_studio_delete` rechaza el borrado si el estudio tiene películas. Los procedimientos no usan `SECURITY DEFINER`, porque PostgreSQL no permite `COMMIT` ni `ROLLBACK` en ellos; por eso el rol `bd_mantenedor` tiene permisos `DML` sobre las tablas que mantiene.

8. Consultas y optimización

8.1. Consultas equivalentes

La consulta A obtiene películas de Drama o Comedia, estrenadas en Estados Unidos entre 2000 y 2009, con rating mayor o igual a 4.0. Usa enlace por `WHERE`, `OR` e `IN`, sin `JOIN`. La consulta B devuelve los mismos resultados con `JOIN`, una CTE y `EXISTS`. La equivalencia se comprobó con `EXCEPT` en ambas direcciones: 0 diferencias.

8.2. Planes antes de la optimización

[COMPLETAR: planes antes]

8.3. Índices creados

Se crearon índices compuestos para evitar visitar el heap al buscar por género y por país, y un índice que cubre año y rating:

```
CREATE INDEX idx_movie_genres_genre_movie
    ON movie_genres (genre_id, movie_id);

CREATE INDEX idx_movie_countries_country_movie
    ON movie_countries (country_id, movie_id);

CREATE INDEX idx_movies_year_rating
    ON movies (release_year, rating) INCLUDE (movie_id, name);
```

Los índices de una sola columna quedaron cubiertos por el prefijo de los nuevos y se eliminaron.

8.4. Planes después de la optimización

[COMPLETAR: planes después]

8.5. Conclusión de la optimización

[COMPLETAR: comparación de tiempos y conclusión]

9. Usuarios y vistas

Se crearon cinco vistas con filtros: `vw_movies_public` oculta descripción y póster; `vw_movies_recent` muestra solo películas desde 2000; `vw_releases_public` muestra solo estrenos ya ocurridos; `vw_releases_upcoming` reserva los estrenos futuros; y `vw_movie_cast_public` muestra el reparto con nombres legibles.

La Tabla 3 resume los niveles de acceso.

Con `SET ROLE` se comprobó que cada rol accede solo a lo permitido y que `audit_log` rechaza `UPDATE` y `TRUNCATE`.

Rol	Acceso
`bd_lectura`	Solo las vistas públicas. No puede leer las tablas base.
`bd_analista`	`SELECT` sobre todas las tablas y vistas, sin escritura.
`bd_mantenedor`	`SELECT`, `DML` sobre las tablas mantenidas y ejecución de los procedimientos.
`bd_auditor`	`SELECT` sobre el modelo y sobre `audit_log`.
`bd_admin`	Control total del esquema, tablas, secuencias y procedimientos.

Cuadro 3: Roles y niveles de acceso.

10. Conclusiones

- La carga en dos capas permitió separar los datos crudos de las transformaciones y validar los conteos al final.
- El modelo de 19 tablas evita redundancia y mantiene la integridad mediante claves y restricciones.
- La comparación de planes permite justificar los índices creados y su efecto en las consultas.
- Los roles y las vistas permiten exponer el catálogo sin dar acceso directo a las tablas base.